UNIVERSIDAD ANDRÉS BELLO

Magíster en Ciencia de Datos e Inteligencia Artificial

Informe Sumativa 1 — Fases 1 y 2

Análisis exploratorio de las tendencias cinematográficas mundiales (2010–2025)

MCDI500 · Programación para la Ciencia de Datos

Profesor	Omar Salinas Silva
Grupo 4	Daniela Baeza Rocha Juan Pablo González Elgueta Elías Manríquez Armijo Yestxander Rada Gutierrez
Repositorio	github.com/yetgx/mcdi500-tmdb-grupo4
Fecha	8 de noviembre de 2026

Santiago, Chile · 2026

Resumen ejecutivo

[150–200 palabras: problema, datos, método, 2–3 hallazgos con cifra, conclusión. Escribir al final.]

1. Introducción y contexto

[Industria del cine 2010–2025: streaming, pandemia, cambios en consumo. Por qué importa.]

2. Problema y objetivos

Pregunta central: *[ej. ¿Qué factores (presupuesto, género, país, idioma, año) se asocian a mayor recaudación y valoración?]*

Objetivo general: Desarrollar un análisis exploratorio de 17 978 películas de TMDB estrenadas entre 2010 y 2025.

Objetivos específicos:

1. *[caracterizar la estructura y calidad de los datos]*
2. *[describir la evolución anual de estrenos, popularidad y valoración]*
3. *[explorar la relación presupuesto–recaudación]*
4. *[identificar países, idiomas y géneros predominantes]*

3. Datos

Atributo	Detalle
Fuente	TMDB Raw Movie Dataset (2010–2025), Evan Christiawan, Zenodo — DOI 10.5281/zenodo.21920642
Licencia	CC BY 4.0 (uso educativo, no comercial)
Tamaño	17 978 filas × 16 columnas · 3,2 MB
SHA-256	`129fbd840dd13857f72ff4673da23820ac73ea548236b1f47baa621438cd0a5c`
Validación	`docs/validacion_dataset.md` — cumple los 11 requisitos del curso

3.1 Diccionario de variables

Variable	Tipo	Rol	Nulos %	Descripción
movie_id	int64	identificador	0	ID TMDB

Variable	Tipo	Rol	Nulos %	Descripción
title	str	identificador	0	Título
release_date	str → datetime	fecha	0	Fecha de estreno
status	str	nominal	0	Constante («Released»)
budget	int64	continua	0	Presupuesto (USD)
revenue	int64	continua	0	Recaudación (USD)
runtime	int64	discreta	0	Duración (min)
genres	str	alta cardinalidad	0,06	Géneros separados por |
production_companies	str	alta cardinalidad	2,75	Productoras separadas por |
production_countries	str	alta cardinalidad	0,98	Países separados por |
spoken_languages	str	alta cardinalidad	0,51	Idiomas hablados
original_language	str	alta cardinalidad	0	Idioma original (80 valores)
vote_average	float64	continua	0	Valoración media
vote_count	int64	continua	0	N.º de votos (mín. 50)
popularity	float64	continua	0	Índice de popularidad TMDB
adult	bool	nominal	0	Constante (`False`)

3.2 Calidad de los datos (hallazgos a documentar)

- `status` y `adult` son constantes: sin poder informativo.
- `budget` y `revenue`: mediana = 0, es decir, el cero codifica «dato no informado», no un valor real. *[cuantificar % de ceros]*
- `runtime` con mínimo 0 y máximo 585: revisar valores atípicos.
- Nulos solo en columnas multivalor (`genres`, `production_*`, `spoken_languages`), máx. 2,75 %.
- Títulos repetidos (17 322 únicos de 17 978): confirmar que no son duplicados de `movie_id`.
- Columnas multivalor separadas por `|`: requieren expansión (`explode`) para contar.

4. Metodología

- Entorno: Python 3.12+, pandas 3.1.0, numpy 2.5.4, semilla 42, dependencias en `requirements.txt`.
- Flujo: `F1/` (definición y exploración) → `F2/` (limpieza y transformación) → `data/processed/`.
- Control de versiones: `main` protegida, ramas por tarea, PR con revisión (`CODEOWNERS`), commits con prefijos `docs/data/feat/fix`.
- Decisiones registradas con motivo y cifra en `docs/bitacora.md`.

5. Análisis exploratorio

Para cada figura: título, ejes con unidades, interpretación de 2–4 líneas con cifra.

5.1 Estrenos por año

[figura + interpretación (¿caída 2020–2021 por pandemia?)]

5.2 Popularidad promedio por año

[figura + interpretación]

5.3 Presupuesto vs. recaudación

[excluir ceros; escala log; correlación]

5.4 Países productores

[top N tras explode de production_countries]

5.5 *[géneros / idiomas / valoración]*

6. Preprocesamiento (Fase 2)

Problema	Tratamiento	Alternativa descartada	Motivo (cifra)
Ceros en budget/revenue	*[NaN / excluir en análisis]*	*[imputar mediana]*	*[% de ceros]*
Nulos multivalor	*[categoría «Desconocido»]*		
Columnas constantes	*[eliminar]*		
Fechas	`to_datetime`, derivar `release_year`		

7. Resultados y discusión

[Responder la pregunta central. 3–5 hallazgos con cifra. Contrastar con el contexto de la sección 1.]

8. Limitaciones

- Presupuesto y recaudación ausentes en gran parte de los registros.

- Sesgo de TMDB hacia producciones occidentales y con más votos (mín. 50 votos).
- Análisis descriptivo: asociación, no causalidad.
- Moneda nominal, sin ajuste por inflación.

9. Conclusiones y trabajo futuro

[1 párrafo + 3 líneas de próximos pasos (Fases 3 y 4).]

10. Contribución del equipo

Integrante	Usuario GitHub	Aporte	Commits / PR
Daniela Baeza Rocha	@Daninela		
Juan González Elgueta	@jp-IArtificial		
Elías Manríquez Armijo	@EliasManriquez		
Yestxander Rada Gutierrez	@yetgx		

Referencias (APA)

- Christiawan, E. (2026). *TMDB Raw Movie Dataset (2010–2025)* [Conjunto de datos]. Zenodo. https://doi.org/10.5281/zenodo.21920642
- The Movie Database (TMDB). (s. f.). https://www.themoviedb.org/
- *[pandas, matplotlib, seaborn, material del curso]*

Anexos

- A. Informe de validación del dataset (`docs/validacion_dataset.md`).
- B. Mapa conceptual Formativa 1 (`F1/Formativa/Final/mcdi500_s1_grupo4.pdf`).
- C. Bitácora de decisiones (`docs/bitacora.md`).